

ИНФОРМАЦИОННАЯ БЕЗОПАСНОСТЬ

УДК 004.056.52

DOI: 10.25206/2310-9793-2023-11-4-94-98

ОБНАРУЖЕНИЕ БОТОВ НА ОСНОВАНИИ ДВИЖЕНИЯ КУРСОРА КОМПЬЮТЕРНОЙ МЫШИ

BOT DETECTION USING MOUSE MOVEMENTS

Н. С. Афанасьева¹, П. С. Ложников²

¹Омский государственный университет путей сообщения, г. Омск, Россия

²Омский государственный технический университет, г. Омск, Россия

N. S. Afanaseva¹, P. S. Lozhnikov²

¹Omsk State Transport University, Omsk, Russia

²Omsk State Technical University, Omsk, Russia

Аннотация. Рассматриваются преимущества обнаружения ботов на основании динамических характеристик движения курсора компьютерной мыши. Проведен анализ существующих способов определения ботов. Рассмотрены общедоступные наборы данных, которые могут быть использованы для нахождения ботов, используя особенности перемещения курсора компьютерной мыши.

Ключевые слова: бот, вредоносный бот, детектор ботов, движение курсора компьютерной мыши, наборы данных динамики мыши.

Abstract. This article discusses the advantages of detecting bots using mouse dynamics. An analysis of existing methods for identifying bots was carried out. We consider publicly available datasets that can be used to find bots using the features of mouse movement.

Keyword: bot, malicious bot, bot detector, mouse movements, mouse dynamics datasets.

I. ВВЕДЕНИЕ

Для обнаружения ботов предлагаются различные подходы. САРТСНА (полностью автоматизированный публичный тест Тьюринга для различения компьютеров и людей) [1], будучи самым известным тестом на определение человека (НП), используется в большинстве веб-ресурсов для активного обнаружения ботов. САРТСНА предлагает задачу, которая легко решается человеком, но затруднительна для ботов. Однако применение САРТСНА в настоящее время не является абсолютной гарантией отслеживания ботов, так как данный тест научились обходить либо с помощью человека, либо используя методы распознавания изображений (OCR). Более того, с развитием глубокого обучения становится возможным взламывать различные типы САРТСНА [2]. Другой подход к обнаружению ботов – использовать пассивный мониторинг входных данных и сравнивать их с показателями человека (НОР) [3]. Его преимуществом является присущая человеку нерегулярность и сложность, что является отличительной чертой человека от бота. Динамические характеристики движения мыши, использование которых относят ко второй группе методов обнаружения, демонстрируют значительные преимущества перед известными методами обнаружения ботов. Во-первых, они могут обеспечивать непрерывное обнаружение на протяжении всего времени работы. Во-вторых, такой способ не требует от пользователя выполнять дополнительные действия, а обнаружение может быть выполнено без ведома пользователя о выполняемых работах.

II. ДЕТЕКТОРЫ БОТОВ

Динамические биометрические образы человека стали широко использоваться не только в вопросах аутентификации пользователя, но и в области обнаружения ботов. К таким образам относят голос, клавиатурный почерк, особенности жестикуляции, динамические характеристики движения мыши и другие.

Движение мыши можно рассматривать как серию движений (треков), где каждый трек представляет собой конкретный и непрерывный физический процесс, инициируемый и завершаемый пользователем [4].

Анализ движения мыши широко используется в современных исследованиях для обнаружения вредоносных ботов. Вредоносные боты представляют собой автономные интеллектуальные продукты, разработанные с целью мошенничества, причинения вреда конечным пользователям или организациям в целом [5]. Для распознавания ботов важную роль имеют следующие преимущества работы с динамическими характеристиками движения мыши:

- распространенность данного устройства и повсеместное использование в системе «человек-компьютер»;
- анализ движения мыши не требует использования дополнительного аппаратного обеспечения, что экономит ресурсы;
- движение курсора отслеживается ненавязчивым и незаметным для конечного пользователя способом [3];
- простота сбора поведенческих данных пользователей в большом масштабе;
- с точки зрения конфиденциальности пользователей обмен данными о динамике мыши гораздо менее проблематичен, чем обмен подписями или голосовыми данными.

В настоящее время существуют несколько детекторов ботов, которые имеют свои особенности и направлены на решение частных задач.

Детектор ботов ВеСАРТСНА-Mouse, представленный в работе [6], анализирует полную траекторию движения мыши, а не отдельные характеристики (продолжительность трека, средняя скорость, изменение положения курсора). Обучается ВеСАРТСНА-Mouse на данных, полученных в результате нейромоторного моделирования динамики мыши. Данный вид детектора не призывает отказаться от существующего инструмента геСАРТСНА, а служит дополнением с использованием вспомогательной информации, предоставляемой динамикой движения мыши. В данной работе представлены два метода создания синтетических траекторий мыши для улучшения обучения и оценки методов обнаружения ботов: первый основан на эвристических функциях, второй – на генеративно-состязательных сетях, в котором синтезируются траектории на основе входного гауссовского шума.

В работе Ризван Ур Рахман и Дипак Сингх Томара [7] предложено десять основных характеристик, таких как источник ввода, степень давления при щелчке мыши, величина горизонтальной прокрутки, величина вертикальной прокрутки, скорость горизонтальной прокрутки, скорость вертикальной прокрутки и энтропия времени, затраченного на перемещение между двумя страницами, время пребывания на странице и скорость набора текста, чтобы проанализировать поведение ботов в веб-приложениях. Разработанная модель основана на двух алгоритмах машинного обучения – K-medoid и наивного Байеса.

В работах Чонга, Еловича и Биндера [8] впервые применилось глубокое обучение для обнаружения ботов на основе характеристик движения мыши. Они предложили применить двумерные сверточные нейронные сети для динамических характеристик движения мыши, представив временные ряды последовательных треков. В своей работе они использовали разницу положений курсора (dx, dy) и значения скорости между двумя соседними точками трека $(\frac{dx}{dt}, \frac{dy}{dt})$. Данный подход доказал свою эффективность и продолжил развитие в работе [9] Антала и Фейера.

При обнаружении ботов на основе динамики мыши с использованием последовательного обучения [10] движение мыши представляет собой числовой вектор $(dx, dy, \frac{dx}{dt}, \frac{dy}{dt})$, на основе которого используется глубокое обучение для обнаружения ботов. В данной работе используются модели глубокого обучения с долговременной памятью (LSTM), одномерная модель сверточной нейронной сети (1D-CNN) и гибридная модель глубокого обучения сверточной нейронной сети в сочетании с долговременной памятью (CNN+LSTM).

Аналогичный подход используется в работе [11]. Но в этом случае входными данными для 1D-CNN является изображения, полученные путем двухэтапного преобразования параметров движения мыши. На первом этапе пространственные характеристики, такие как расстояние между двумя соседними точками и траек-

тория мыши, отображается в изображение. Затем, используется информация о цвете для демонстрации кинематической информации каждой точки.

Отдельным вопросом остается обнаружение ботов, воспроизводящих сеансы реальных пользователей. Существуют скрипты, которые фиксируют не только общую статистику поведения пользователей, а записывают целые сеансы работы отдельных пользователей на странице [12]. Противодействие таким ботам рассмотрено в ряде работ [6, 13, 14]. В [14] рассматривается аутентификация пользователей, а не идентификация ботов. В [13] рассматриваются блог-боты. В [6] учитывается наличие веб-сайтов, на которых возможна генерация повторяющихся сеансов настоящими пользователями, например, новостные, банковские сайты.

II. НАБОРЫ ДАННЫХ ДИНАМИКИ МЫШИ

Вышеперечисленные работы использовали для анализа два типа набора данных. Первый – общедоступные датасеты, которые выложены в открытый доступ и могут использоваться любыми желающими; второй – самостоятельно собранные данные. Причем второй тип датасетов может создаваться двумя способами: пользователи выполняют определенную заданную задачу с помощью мыши (метод управляемой среды), либо пользователей не инструктируют и они самостоятельно перемещают курсор мыши (метод неуправляемой среды).

К наиболее часто используемым наборам данных относят: Balabit [15], Bogazici [16], Attentive Cursor [17], SapiMouse [18], Chao Shen [19] и DFL [20], ReMouse [6]. Ниже представлено краткое описание каждого набора данных.

Опубликованный в 2016 году набор данных Balabit [15] относится к категории наборов неуправляемой среды и включает в себя информацию о положении курсора и времени трека для 10 пользователей, подключенных к удаленному серверу. Во время сбора данных пользователям предлагалось выполнять свои обычные повседневные действия. События мыши содержат следующие данные: временную метку, нажатую кнопку, состояние мыши и координаты указателя мыши. Основная цель сбора набора данных Balabit заключалась в том, чтобы узнать, как вовлеченные пользователи используют свою мышь, чтобы иметь возможность защитить их от несанкционированного использования их учетных записей. Данные обучения и тестирования представлены в виде сеансов в наборе данных; однако тестовые сеансы намного короче тренировочных.

Набор данных Bogazici [16], опубликованный в 2021 году, также попадает в категорию наборов неуправляемой среды и включает в себя модели поведения 24 пользователей при использовании мыши, собранные за один месяц. Участники сбора данных были выбраны с разных должностей в одной компании, чтобы получить разные модели поведения пользователей при взаимодействии с разными программами и инструментами в офисной среде. На компьютер каждого пользователя загружалась специально разработанная программа, которая собирала движения мыши пользователя, не привязываясь к конкретной задаче и не мешая пользователю выполнять свою обычную повседневную деятельность. Набор данных состоит из типа действия мыши, временной метки, пространственных координат, состояние и имя окна приложения.

В наборе данных управляемой среды 2020 года [17] перед пользователями была поставлена задача веб-поиска с целью определения областей внимания и демографической информации. Авторы зафиксировали реальное поведение примерно 3000 людей, выполняющих транзакционную задачу веб-поиска. Собранные информация включает в себя следующее: положение курсора мыши, метку времени, имя события.

Набор данных [18], собранный в 2020 году, также получен управляемым методом. Он содержит данные о движении мышей от 120 пользователей (92 мужчин и 28 женщин в возрасте от 18 до 53 лет). Участникам было предложено выполнить четыре различных действия, каждое из которых было связано с геометрическими фигурами на веб-странице, включая щелчок правой и левой кнопкой мыши, а также действия перетаскивания. В наборе данных с каждым участником было связано два файла, каждый файл соответствовал одному и трехминутным сеансам соответственно. Набор данных содержит в себе следующую информацию: положение курсора мыши, тип события (перемещение, перетаскивание, нажатие или отпускание кнопки мыши) и соответствующую временную метку.

Набор Chao Shen состоит из информации о динамике мышей 28 пользователей, собранных в течение двух месяцев [19]. Сеанс включает около тридцати минут активности мыши каждого пользователя. В наборе данных каждая операция мыши была представлена в виде характеристик: тип действия, тип приложения, область экрана и положение окна и соответствующих им временных меток. Набор данных был собран с целью непрерывной аутентификации пользователей.

Набор данных DFL [20] был собран в 2018 году в неуправляемой среде и содержит следующую информацию о действиях пользователей с мышью: отметка времени, кнопка (левая, правая, без кнопки), состояние (перемещение, нажатие, отпускание, перетаскивание) и координаты.

Набор данных ReMouse [6], собранный в 2023 году, содержит информацию о динамике мышей 100 пользователей, проживающих в различных странах и использующих разные устройства. Отличительной особенностью данного набора является наличие повторяющихся сеансов, которые получены в результате выполнения пользователями идентичных задач – повторяющаяся последовательность шагов. Данный набор включает в себя информацию о положении курсора мыши, скорости перемещения курсора и размер окна приложений.

III. ОБСУЖДЕНИЕ РЕЗУЛЬТАТОВ

Представленные работы в области обнаружения ботов подтверждают актуальность проблемы. Стоит отметить, что имеющиеся методы и наборы данных имеют особенности и ограничения применения. Для специализированных задач есть необходимость создания дополнительных датасетов, включающих в себя динамику движения мыши.

IV. ВЫВОДЫ И ЗАКЛЮЧЕНИЕ

В работе проведен углубленный анализ существующих подходов для определения ботов. Также представлен перечень общедоступных наборов данных о динамике мыши, на основании которых происходил поиск ботов. Эта информация может быть использована для обоснованного выбора набора данных при дальнейшем исследовании детекторов ботов.

ИСТОЧНИК ФИНАНСИРОВАНИЯ. БЛАГОДАРНОСТИ

Работа выполнена при финансовой поддержке Министерства цифрового развития, связи и массовых коммуникаций Российской Федерации (Минцифры России), соглашение № 40469-07/23-К от 30.06.2023.

СПИСОК ЛИТЕРАТУРЫ

1. What is recaptcha? URL: <https://www.google.com/recaptcha/about/> (date accessed: 03.09.2023).
2. Stark F., Hazırba, S. C., Triebel R., Cremers D. Captcha recognition with active deep learning // Workshop new challenges in neural computation : machine learning reports. Germany, 2015. P. 95–102.
3. Leiva L. A., Arapakis I., Iordanou C. My mouse, my rules: Privacy issues of behavioral user profiling via mouse tracking // CHIIR '21 : proceedings of the 2021 Conference on Human Information Interaction and Retrieval. Canberra, Australia, 2021. P. 51–61. <https://doi.org/10.1145/3406522.3446011>.
4. Katerina T., Nicolaos P. Mouse behavioral patterns and keystroke dynamics in End-User Development: What can they tell us about users' behavioral attributes? // Computers in Human Behavior. 2018. Vol. 83. P. 288–305. <https://doi.org/10.1016/j.chb.2018.02.012>.
5. Афанасьева Н. С., Елизаров Д. А., Ложников П. С. Вредоносные боты в современном мире. Анализ, последствия и возможные способы борьбы с ними // Информационная безопасность цифровой экономики : материалы XIX науч.-практ. конф., Улан-Удэ, 07–11 июня. 2023 г. Новосибирск : Изд-во Сибир. гос. ун-та телекоммуникаций и информатики, 2023. С. 84–92.
6. Sadeghpour S., Vlajic N. ReMouse Dataset: On the Efficacy of Measuring the Similarity of Human-Generated Trajectories for the Detection of Session-Replay Bots // Journal of Cybersecurity and Privacy. 2023. Vol. 3, no. 1. P. 95–117. <https://doi.org/10.3390/jcp3010007>.
7. Rahman R. U., Tomar D. S. A new web forensic framework for bot crime investigation // Forensic Science International: Digital Investigation. 2020. Vol. 33. P. 300943. <https://doi.org/10.1016/j.fsidi.2020.300943>.
8. Chong P., Elovici Y., Binder A. User authentication based on mouse dynamics using deep neural networks: A comprehensive study // IEEE Transactions on Information Forensics and Security. 2019. Vol. 15. P. 1086–1101. DOI: 10.1109/TIFS.2019.2930429.
9. Antal M., Fejér N., Buza K. SapiMouse: Mouse dynamics-based user authentication using deep feature learning // 2021 IEEE 15th International Symposium on Applied Computational Intelligence and Informatics (SACI). Timisoara, Romania : IEEE, 2021. P. 61–66. DOI: 10.1109/SACI51354.2021.9465583.

10. Niu H., Chen J., Zhang Z., Cai Z. Mouse Dynamics Based Bot Detection Using Sequence Learning // Biometric Recognition : 15th Chinese Conference, CCBR 2021, Shanghai, China, September 10–12, 2021, Proceedings 15. Springer International Publishing, 2021. P. 49–56. https://doi.org/10.1007/978-3-030-86608-2_6.
11. Wei A., Zhao Y., Cai Z. A deep learning approach to web bot detection using mouse behavioral biometrics // Biometric Recognition : 14th Chinese Conference, CCBR 2019, Zhuzhou, China, October 12–13, 2019, Proceedings 14. Springer International Publishing, 2019. P. 388–395. https://doi.org/10.1007/978-3-030-31456-9_43.
12. Панасенко, А. Популярные сервисы веб-аналитики незаконно собирают персональные данные. URL: <https://www.anti-malware.ru/news/2017-11-23-3/24884> (дата обращения: 09.09.2023).
13. Chu Z., Gianvecchio S., Wang H. Bot or human? A behavior-based online bot detection system // From Database to Cyber Security : Essays Dedicated to Sushil Jajodia on the Occasion of His 70th Birthday. Springer, 2018. P. 432–449. https://doi.org/10.1007/978-3-030-04834-1_21.
14. Scrap: synthetically composed replay attacks vs. adversarial machine learning attacks against mouse-based biometric authentication / Solano J., Lopez C., Rivera E. [et al.] // AISec'20 : Proceedings of the 13th ACM Workshop on Artificial Intelligence and Security. 2020. P. 37–47. <https://doi.org/10.1145/3411508.3421378>.
15. Antal M., Fejér N. Mouse dynamics based user recognition using deep learning // Acta Universitatis Sapientiae, Informatica. 2020. Vol. 12, no. 1. P. 39–50. DOI: 10.2478/ausi-2020-0003.
16. Kılıç A. A., Yıldırım M., Anarım E. Bogazici mouse dynamics dataset // Data in Brief. 2021. Vol. 36. P. 107094. <https://doi.org/10.1016/j.dib.2021.107094>.
17. Leiva L. A., Arapakis I. The Attentive Cursor Dataset // Frontiers in Human Neuroscience. 2020. Vol. 14. P. 565664. <https://doi.org/10.3389/fnhum.2020.565664>.
18. Sapimouse. URL: <https://github.com/margitalantal68/sapimouse> (date accessed: 05.09.2023).
19. Shen C., Cai Z., Guan X. Continuous authentication for mouse dynamics: A pattern-growth approach // IEEE/IFIP international conference on dependable systems and networks (DSN 2012). Boston, MA, USA : IEEE, 2012. P. 1–12. DOI: 10.1109/DSN.2012.6263955.
20. Karim M., Hasanuzzaman Md. A Study on Mouse Movement Features to Identify User // Scientific Research Journal. 2020. Vol. 8, no. 4. P. 77–82. DOI: 10.31364/SCIRJ/v8.i4.2020.P0420766.